Trabalho de Conformidade do Curso de Dados Abertos para Controle Social

October 29, 2021

O objetivo do presente trabalho consistem verificar quais empresas de PEPs (Pessoas Politicamente Expostas) que receberam recursos dos próprios municípios em que têm mandatos.

Para isso serão utilizado dados do Portal de Transparência Municipal do TCESP, base de dados públicos de CNPJ da SRF e dados do Portal da Transparência da CGU.

Atenção: Como o presente trabalho é para fins educacionais, os nomes, CPFs e CNPJs foram alterados, mas as estruturas são idênticas às das tabelas originais.

1 Importar as bibliotecas utilizadas

[1]:
```
import os
import shutil

import folium
import pandas as pd
import sqlalchemy
import seaborn as sns
```

2 Carregar Dados

[2]:
```
diretorio_dados = 'dados'
```

2.1 Carregar dados de banco

O banco de dados possui três tabelas: despesas_consolidado, empresas e sócios

[3]:
```
arquivo_sqlite = 'banco_trabalho06.db'
filepath_arquivo_sqlite = os.path.join(diretorio_dados, arquivo_sqlite)
```

[4]:
```
url_banco = "sqlite:///{}".format(filepath_arquivo_sqlite)
engine = sqlalchemy.create_engine(url_banco)
```

2.1.1 Despesas

É a totalização de valores pagos a empresas por município, valores aproximadamente acima de 100 mil reais.

A consolidação foi realizada a partir da tabela despesas do TCE/SP. Os nomes de empresas, cnpjs e municípios foram alterados.

A coluna **ds_municipio** é o nome do município fictício, **nr_identificador_despesa** o CNPJ da empresa que recebeu o valor da coluna soma e **ds_despesa** a razão social fictícia da empresa.

Os dados originais podem ser obtidos em: https://transparencia.tce.sp.gov.br/conjunto-de-dados

[5]:
```
sql = 'SELECT * FROM despesas_consolidado'
despesas = pd.read_sql(sql, engine, index_col=None)
```

Aqui podemos visualizar uma amostra dos dados

[6]:
```
despesas.sample(5)
```

[6]:

	ds_municipio	nr_identificador_despesa	ds_despesa	soma
7964	LUND	01488263000192	ZALAN AMBIENTAL SA	475913.69
9997	CATANIO	50889774000128	CHIARA COMUNICACAO EPP	391517.82
18279	SALMAZZO	08571215000111	SUZANNE COMERCIO EIRELLI	168479.45
20241	CAIMAR	05253198000168	MANATO AGROPECUARIA	134301.00
2546	POURBAIX	67592103000963	IGOR SUPERMERCADO SA	1845633.76

Com o comando abaixo, podemos ver que a tabela possui 25.885 registros; não possui dados nulos e há apenas uma coluna com dados numéricos.

[7]:
```
despesas.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 25885 entries, 0 to 25884
Data columns (total 4 columns):
 #   Column                   Non-Null Count  Dtype
---  ------                   --------------  -----
 0   ds_municipio             25885 non-null  object
 1   nr_identificador_despesa  25885 non-null  object
 2   ds_despesa               25885 non-null  object
 3   soma                     25885 non-null  float64
dtypes: float64(1), object(3)
memory usage: 809.0+ KB
```

Múnicipios Únicos

[8]:
```
municipios_sao_paulo = 645
quantidade_municipios_unicos = len(despesas['ds_municipio'].unique())
proporcao = round(quantidade_municipios_unicos/municipios_sao_paulo*100,1)

print('O estado de São Paulo possui {} municipios'.format(municipios_sao_paulo))
print('A amostra utilizada, possui {} municipios unicos'.
 ↪format(quantidade_municipios_unicos))
print('Representando {}% dos municipios de SP'.format(proporcao))
```

```
O estado de São Paulo possui 645 municipios
A amostra utilizada, possui 644 municipios unicos
Representando 99.8% dos municipios de SP
```

Distribuição Despesas Município

[9]:
```
sns.set(rc={'figure.figsize':(12, 8)})

ax = sns.histplot(despesas, x='soma', log_scale=True)

ax.set(title='Distribuição de Despesas')
ax.set(xlabel='Despesas', ylabel='Contagem')
```

[9]:
```
[Text(0.5, 0, 'Despesas'), Text(0, 0.5, 'Contagem')]
```

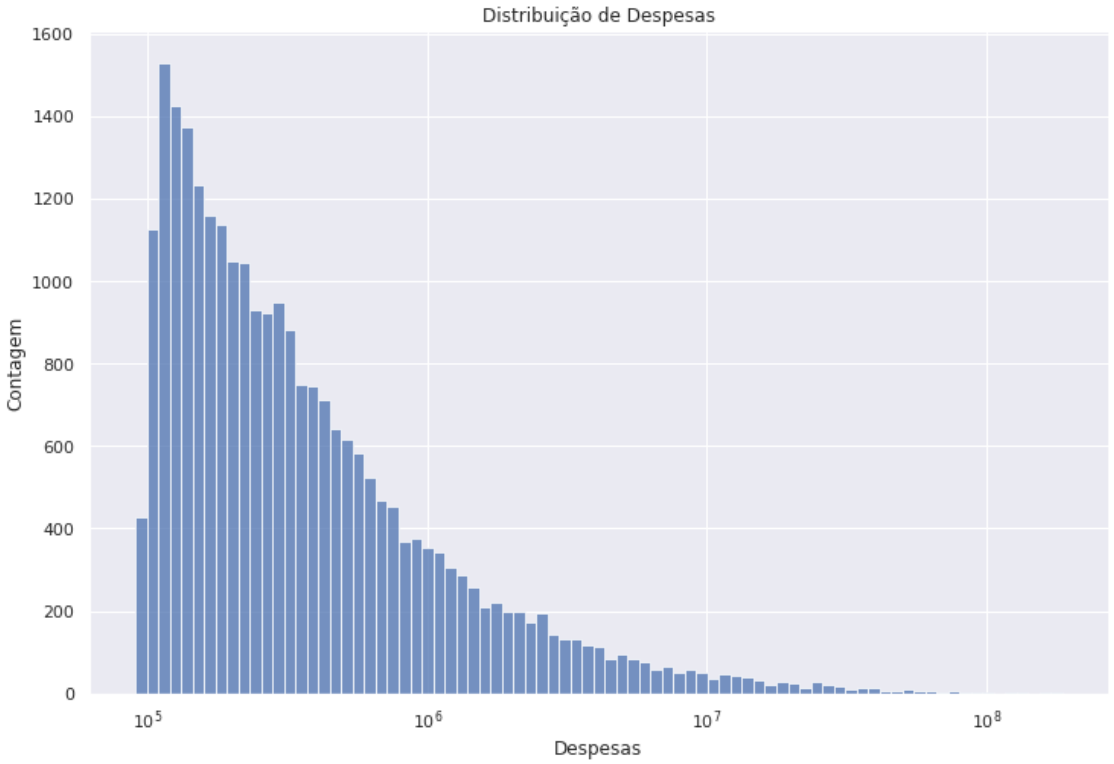

Municípios Que Mais Gastaram

[10]:
```
municipios_despesas = despesas.groupby('ds_municipio').sum()
municipios_despesas = municipios_despesas.sort_values('soma', ascending=False)
top_10_municipio_despesas = municipios_despesas.head(10).reset_index()
```

[11]:
```
top_10_municipio_despesas
```

[11]:

	ds_municipio	soma
0	ROZARIO	1.223180e+09
1	DALAGO	9.643243e+08
2	HELFER	9.434388e+08
3	ZACCAI	9.342326e+08
4	HOLZBACH	7.990991e+08
5	PROITE	7.534733e+08
6	POVINHA	7.382816e+08
7	PATELLI	6.120559e+08
8	MARTEL	6.112997e+08
9	KANDELMAN	5.709025e+08

[12]:
```
ax = sns.barplot(data=top_10_municipio_despesas, x='soma', y='ds_municipio')

ax.set(title='Top 10 de Municípios com Maiores Despesas')
ax.set(xlabel='Despesas', ylabel='Município')
```

[12]:
```
[Text(0.5, 0, 'Despesas'), Text(0, 0.5, 'Município')]
```

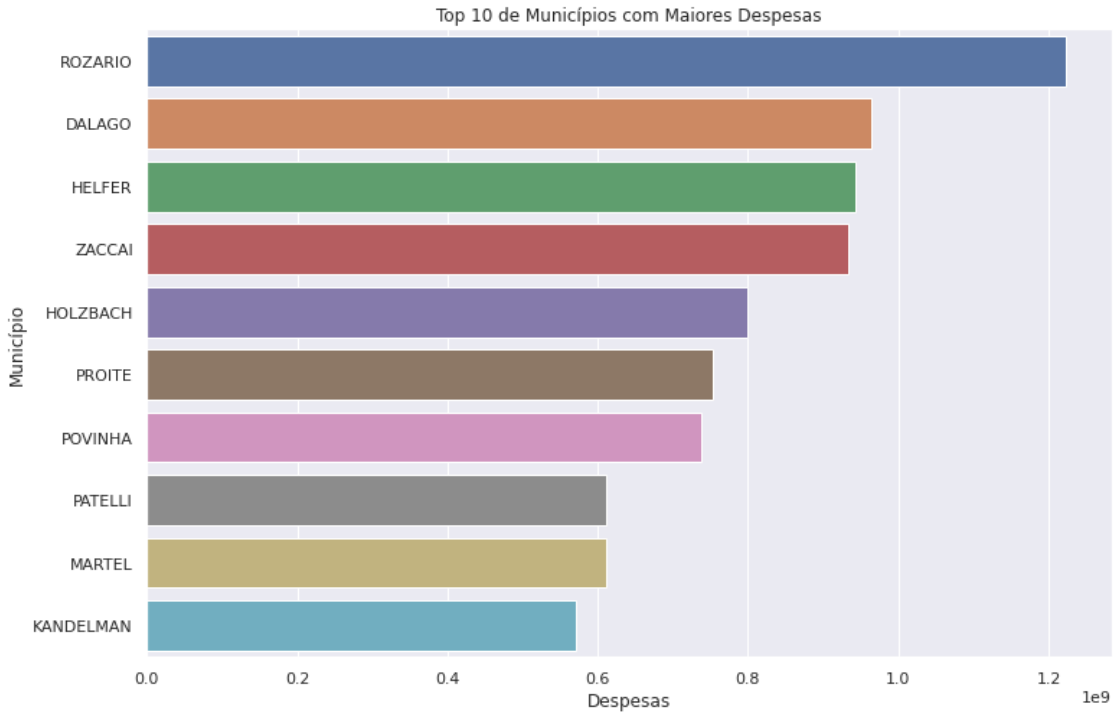

2.1.2 Empresas

Tabela de empresas da receita federal.

Possui dados alterados, mas a estrutura das colunas é semelhante a base pública da Receita Federal.

[13]:
```
sql = 'SELECT * FROM empresas'
empresas = pd.read_sql(sql, engine, index_col=None)
```

Aqui podemos visualizar uma amostra dos dados

[14]:
```
empresas.sample(5)
```

[14]:

	cnpj	matriz_filial	razao_social	\
4017	22373705000199	1	MADISON EQUIPAMENTOS EIRELLI	
2704	02664857000151	1	JANNIK IMOBILIARIA	
2830	25066995000125	1	LIONEL INCORPORADORA EIRELLI	
1109	17611691000119	1	BIBORKA COSMETICOS	
1786	08369911000148	1	NANA ESPORTIVOS	

	nome_fantasia	situacao	data_situacao	motivo_situacao	nm_cidade_exterior	\
4017		02	20200101	00		
2704		02	20200101	00		
2830		02	20200101	00		
1109		02	20200101	01		

```
1786                    02      20200101              00

     cod_pais nome_pais  … email qualif_resp capital_social porte  \
4017                     …                    0.000000e+00    05
2704                     …                    0.000000e+00    05
2830                     …                    7.332226e+06    01
1109                     …                    9.165282e+05    05
1786                     …                    7.332226e+06    01

     opc_simples data_opc_simples data_exc_simples opc_mei sit_especial  \
4017           0                                        N
2704           0                                        N
2830           5                                        N
1109           0                                        N
1786           5                                        N

     data_sit_especial
4017
2704
2830
1109
1786

[5 rows x 38 columns]
```

Com o comando abaixo, podemos ver que a tabela possui 5.779 registros; não possui dados nulos e há apenas uma coluna com dados numéricos.

[15]:
```
empresas.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5779 entries, 0 to 5778
Data columns (total 38 columns):
 #   Column              Non-Null Count  Dtype
---  ------              --------------  -----
 0   cnpj                5779 non-null   object
 1   matriz_filial       5779 non-null   object
 2   razao_social        5779 non-null   object
 3   nome_fantasia       5779 non-null   object
 4   situacao            5779 non-null   object
 5   data_situacao       5779 non-null   object
 6   motivo_situacao     5779 non-null   object
 7   nm_cidade_exterior  5779 non-null   object
 8   cod_pais            5779 non-null   object
 9   nome_pais           5779 non-null   object
 10  cod_nat_juridica    5779 non-null   object
 11  data_inicio_ativ    5779 non-null   object
 12  cnae_fiscal         5779 non-null   object
```

```
 13  tipo_logradouro     5779 non-null   object
 14  logradouro          5779 non-null   object
 15  numero              5779 non-null   object
 16  complemento         5779 non-null   object
 17  bairro              5779 non-null   object
 18  cep                 5779 non-null   object
 19  uf                  5779 non-null   object
 20  cod_municipio       5779 non-null   object
 21  municipio           5779 non-null   object
 22  ddd_1               5779 non-null   object
 23  telefone_1          5779 non-null   object
 24  ddd_2               5779 non-null   object
 25  telefone_2          5779 non-null   object
 26  ddd_fax             5779 non-null   object
 27  num_fax             5779 non-null   object
 28  email               5779 non-null   object
 29  qualif_resp         5779 non-null   object
 30  capital_social      5779 non-null   float64
 31  porte               5779 non-null   object
 32  opc_simples         5779 non-null   object
 33  data_opc_simples    5779 non-null   object
 34  data_exc_simples    5779 non-null   object
 35  opc_mei             5779 non-null   object
 36  sit_especial        5779 non-null   object
 37  data_sit_especial   5779 non-null   object
dtypes: float64(1), object(37)
memory usage: 1.7+ MB
```

Sócios Tabela de sócios da receita federal.

Possui dados alterados, mas a estrutura das colunas é semelhante a base pública da Receita Federal.

Os dados originais podem ser obtidos em: https://www.gov.br/receitafederal/pt-br/assuntos/orientacao-tributaria/cadastros/consultas/dados-publicos-cnpj

[16]:
```
sql = 'SELECT * FROM socios'
socios = pd.read_sql(sql, engine, index_col=None)
```

Aqui podemos visualizar uma amostra dos dados

[17]:
```
socios.sample(5)
```

[17]:

	cnpj	tipo_socio	nome_socio	cnpj_cpf_socio	\
5464	27806084000177	2	SIVAL SARGE	***634968**	
1313	14567185000378	2	MANZIN CAUME DE MAMADI	***122008**	
3632	13000032000197	2	LAERTE RUITA IASSIM	***499408**	
4917	13722521000116	2	EDENICIO SHYLENE COOPE	***449298**	
2501	13783359000530	2	HELIO RUSHANSKY CORAT	***331538**	

```
     cod_qualificacao  perc_capital data_entrada cod_pais_ext nome_pais_ext  \
5464               49           0.0     20200101
1313               59           0.0     20200101
3632               49           0.0     20200101
4917               59           0.0     20200101
2501               59           0.0     20200101

     cpf_repres nome_repres cod_qualif_repres
5464                                      00
1313                                      00
3632                                      00
4917                                      00
2501                                      00
```

Com o comando abaixo, podemos ver que a tabela possui 5.825 registros; não possui dados nulos e há apenas uma coluna com dados numéricos.

[18]:
```
socios.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5825 entries, 0 to 5824
Data columns (total 12 columns):
 #   Column             Non-Null Count  Dtype
---  ------             --------------  -----
 0   cnpj               5825 non-null   object
 1   tipo_socio         5825 non-null   object
 2   nome_socio         5825 non-null   object
 3   cnpj_cpf_socio     5825 non-null   object
 4   cod_qualificacao   5825 non-null   object
 5   perc_capital       5825 non-null   float64
 6   data_entrada       5825 non-null   object
 7   cod_pais_ext       5825 non-null   object
 8   nome_pais_ext      5825 non-null   object
 9   cpf_repres         5825 non-null   object
 10  nome_repres        5825 non-null   object
 11  cod_qualif_repres  5825 non-null   object
dtypes: float64(1), object(11)
memory usage: 546.2+ KB
```

2.2 Carregar dados de Pessoas Expostas Politicamente

As Pessoas Expostas Politicamente são os agentes públicos que desempenham ou tenham desempenhado, nos cinco anos anteriores, no Brasil ou em países, territórios e dependências estrangeiros, cargos, empregos ou funções públicas relevantes, assim como seus representantes, familiares e outras pessoas de seu relacionamento próximo.

Possui dados alterados, mas a estrutura das colunas é semelhante a base pública do Portal da Transparência.

O arquivo original pode ser obtido em http://www.portaldatransparencia.gov.br/download-de-dados/pep

[19]:
```
arquivo_peps = 'PEP_SP.csv'
filepath_arquivo_pep = os.path.join(diretorio_dados, arquivo_peps)
```

[20]:
```
peps = pd.read_csv(filepath_arquivo_pep, sep=';')
```

Aqui podemos visualizar uma amostra dos dados

[21]:
```
peps.sample(5)
```

[21]:

	CPF	Nome_PEP	Sigla_Função	\
3482	***.438.918-**	ZANOLINE YANKOUS DIGEZIO DE GIDEONY	VEREAD	
979	***.123.248-**	NEIDE JODA LANUZIA PENUELA CHIMANGO	VEREAD	
6307	***.814.438-**	MICHEL BRANCIFORTE ACHINELIS	VEREAD	
1964	***.240.058-**	DELU SETTIMI	VEREAD	
5387	***.697.298-**	MILTON MARGENTE DA SUSAKO	VEREAD	

	Descrição_Função	Nível_Função	Nome_Órgão	\
3482	VEREADOR	NaN	MUN. DE COSANDEY-SP	
979	VEREADOR	NaN	MUN. DE MENERES-SP	
6307	VEREADOR	NaN	MUN. DE ABECASSIS-SP	
1964	VEREADOR	NaN	MUN. DE BEZERR-SP	
5387	VEREADOR	NaN	MUN. DE CAPELLESSO-SP	

	Data_Início_Exercício	Data_Fim_Exercício	Data_Fim_Carência	uf_orgao
3482	01/01/2017	31/12/2020	31/12/2025	SP
979	01/01/2017	31/12/2020	31/12/2025	SP
6307	01/01/2017	31/12/2020	31/12/2025	SP
1964	01/01/2017	31/12/2020	31/12/2025	SP
5387	01/01/2017	31/12/2020	31/12/2025	SP

Com o comando abaixo, podemos ver que a tabela possui 7.690 registros; possui apenas o coluna **Nível_Função** com dados nulos.

[22]:
```
peps.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 7690 entries, 0 to 7689
Data columns (total 10 columns):
 #   Column                Non-Null Count  Dtype
---  ------                --------------  -----
 0   CPF                   7690 non-null   object
 1   Nome_PEP              7690 non-null   object
 2   Sigla_Função          7690 non-null   object
 3   Descrição_Função      7690 non-null   object
 4   Nível_Função          0 non-null      float64
```

```
 5   Nome_Órgão              7690 non-null   object
 6   Data_Início_Exercício   7690 non-null   object
 7   Data_Fim_Exercício      7690 non-null   object
 8   Data_Fim_Carência       7690 non-null   object
 9   uf_orgao                7690 non-null   object
dtypes: float64(1), object(9)
memory usage: 600.9+ KB
```

3 Execução

[23]:
```
# Definir diretorio saida
diretorio_saida_dados = 'saida'

# Remover diretorio saida, se houver
shutil.rmtree(diretorio_saida_dados, ignore_errors=True)

# Criar diretorio saida
os.makedirs(diretorio_saida_dados, exist_ok=True)
```

3.1 Tratamento dos dados

Alguns dados precisam ser tratados antes da análise.

3.1.1 Empresa

A coluna **data_situacao** está no formato YYYMMDD, para facilitar a análise, vamos criar a coluna **data_situacao_normalizado** com o formato YYYY-MM-DD

[24]:
```
empresas['data_situacao'].sample(5)
```

[24]:
```
3489    20200101
924     20200101
2296    20200101
1352    20200101
2946    20200101
Name: data_situacao, dtype: object
```

[25]:
```
empresas['data_situacao_normalizado'] = pd.
 ↪to_datetime(empresas['data_situacao']).dt.date
```

[26]:
```
empresas['data_situacao_normalizado'].sample(5)
```

[26]:
```
3668    2020-01-01
2825    2020-01-01
3416    2020-01-01
3384    2020-01-01
5035    2020-01-01
```

```
Name: data_situacao_normalizado, dtype: object
```

3.1.2 Socios

A coluna **data_entrada** está no formato YYYMMDD, para facilitar a análise, vamos criar a coluna **data_entrada_normalizado** com o formato YYYY-MM-DD

[27]:
```
socios['data_entrada'].sample(5)
```

[27]:
```
4867    20200101
1057    20200101
5659    20200101
2353    20200101
5629    20200101
Name: data_entrada, dtype: object
```

[28]:
```
socios['data_entrada_normalizado'] = pd.to_datetime(socios['data_entrada']).dt.
↪date
```

[29]:
```
socios['data_entrada_normalizado'].sample(5)
```

[29]:
```
1220    2020-01-01
4327    2020-01-01
1065    2020-01-01
4471    2020-01-01
1507    2020-01-01
Name: data_entrada_normalizado, dtype: object
```

3.1.3 Pessoas Politicamente Expostas

A coluna **CPF** possuem pontuação, vamos criar a coluna **CPF_normalizado** sem elas.

[30]:
```
peps['CPF'].sample(5)
```

[30]:
```
2572    ***.314.458-**
3168    ***.391.178-**
6553    ***.850.358-**
4030    ***.515.838-**
4155    ***.530.108-**
Name: CPF, dtype: object
```

[31]:
```
peps['CPF_normalizado'] = peps['CPF'].str.replace(".", "", regex=False).str.
↪replace("-", "", regex=False)
```

[32]:
```
peps['CPF_normalizado'].sample(5)
```

[32]:
```
4940    ***638528**
2992    ***364378**
6826    ***888478**
2163    ***267098**
6164    ***796278**
Name: CPF_normalizado, dtype: object
```

Na coluna **Nome_Órgão** vamos filtrar dados extras e manter apenas o nome do município na coluna **Municipio_normalizado**

[33]:
```
peps['Nome_Órgão'].sample(5)
```

[33]:
```
546     MUN. DE SHIHONMATSU-SP
1084         MUN. DE CAIMAR-SP
3461            MUN. DE MOO-SP
7633     MUN. DE SCHIAVETTI-SP
4991        MUN. DE KOVALIK-SP
Name: Nome_Órgão, dtype: object
```

[34]:
```
peps['Municipio_normalizado'] = peps['Nome_Órgão'].str.replace("MUN. DE ", "",␣
↪regex=False).str.replace("-SP", "", regex=False)
```

[35]:
```
peps['Municipio_normalizado'].sample(5)
```

[35]:
```
2891         DALAGO
4448        ARNEIRO
3947    CASTALDELLI
57           MORIBE
1887    POKRIWIECKI
Name: Municipio_normalizado, dtype: object
```

As coluna **Data_Início_Exercício**, **Data_Fim_Exercício** e **Data_Fim_Carência** estão no formato YYYY/MM/DD, para facilitar a análise, vamos criar a colunas **Data_Inicio_Exercicio_normalizado**, **Data_Fim_Exercicio_normalizado** e **Data_Fim_Carência_normalizado** com o formato YYYY-MM-DD

[36]:
```
peps['Data_Início_Exercício'].sample(5)
```

[36]:
```
6762    01/01/2017
6520    01/01/2017
1523    01/01/2017
5499    01/01/2017
560     01/01/2017
Name: Data_Início_Exercício, dtype: object
```

[37]:
```
peps['Data_Fim_Exercício'].sample(5)
```

[37]:
```
5162    31/12/2020
3492    31/12/2020
2097    31/12/2020
1140    31/12/2020
7032    31/12/2020
Name: Data_Fim_Exercício, dtype: object
```

[38]:
```
peps['Data_Fim_Carência'].sample(5)
```

[38]:
```
6840    31/12/2025
5675    31/12/2025
676     31/12/2025
3002    31/12/2025
297     31/12/2025
Name: Data_Fim_Carência, dtype: object
```

[39]:
```
peps['Data_Inicio_Exercicio_normalizado'] = pd.
 ↪to_datetime(peps['Data_Início_Exercício']).dt.date
peps['Data_Fim_Exercicio_normalizado'] = pd.
 ↪to_datetime(peps['Data_Fim_Exercício']).dt.date
peps['Data_Fim_Carência_normalizado'] = pd.
 ↪to_datetime(peps['Data_Fim_Carência']).dt.date
```

[40]:
```
peps['Data_Inicio_Exercicio_normalizado'].sample(5)
```

[40]:
```
490     2017-01-01
786     2017-01-01
3409    2017-01-01
7460    2017-01-01
4994    2017-01-01
Name: Data_Inicio_Exercicio_normalizado, dtype: object
```

[41]:
```
peps['Data_Fim_Exercicio_normalizado'].sample(5)
```

[41]:
```
6332    2020-12-31
1072    2020-12-31
1284    2020-12-31
3702    2020-12-31
4808    2020-12-31
Name: Data_Fim_Exercicio_normalizado, dtype: object
```

[42]:
```
peps['Data_Fim_Carência_normalizado'].sample(5)
```

[42]:
```
5719    2025-12-31
2875    2025-12-31
4945    2025-12-31
1129    2025-12-31
```

```
5709    2025-12-31
Name: Data_Fim_Carência_normalizado, dtype: object
```

3.2 Gerar Banco de Dados

3.2.1 Copiar banco original para diretorio de saida

[43]:
```
arquivo_banco_saida = 'output.db'
filepath_arquivo_banco_saida = os.path.join(diretorio_saida_dados,␣
 ↪arquivo_banco_saida)
shutil.copyfile(filepath_arquivo_sqlite, filepath_arquivo_banco_saida)
```

[43]:
```
'saida/output.db'
```

3.2.2 Gravar tabela de prefeitos_vereadores em banco gerado

[44]:
```
url_banco = "sqlite:///{}".format(filepath_arquivo_banco_saida)
engine_banco_saida = sqlalchemy.create_engine(url_banco)
```

[45]:
```
peps.to_sql('peps', con=engine_banco_saida)
```

3.3 Consultar Empresas Relacionadas com Pessoas Politicamente Expostas que Receberam Recursos

[46]:
```
sql = 'SELECT \
  des.ds_municipio AS [Nome_Municipio_Ficticio], \
  des.nr_identificador_despesa AS [CNPJ_Empresa_Beneficiaria], \
  des.ds_despesa AS [Razao_Social_Empresa_Beneficiaria], \
  des.soma AS [Valor_Total], \
  emp.cnpj AS [CNPJ_RFB], \
  emp.razao_social AS [Razao_Social_RFB], \
  CASE emp.situacao \
    WHEN "01" THEN "NULA" \
    WHEN "02" THEN "ATIVA" \
    WHEN "03" THEN "SUSPENSA" \
    WHEN "04" THEN "INAPTA" \
    WHEN "08" THEN "BAIXADA" \
  END AS [Situacao_Cadastral_RFB], \
  CAST(emp.data_situacao AS DATE) AS [Data_Situacao_Cadastral_RFB], \
  emp.cod_nat_juridica AS [Codigo_Natureza_Juridica_RFB], \
  CAST(emp.data_inicio_ativ AS DATE) AS [Data_Inicio_Atividade_RFB], \
  emp.cnae_fiscal AS [CNAE_Fiscal_RFB], \
  emp.municipio AS [Municipio_RFB], \
  emp.uf AS [UF_RFB], \
  soc.nome_socio AS [Nome_Socio_RFB], \
  soc.cnpj_cpf_socio AS [CPF_Socio_RFB], \
  CAST(soc.data_entrada AS DATE) AS [Data_Entrada_Socio_RFB], \
```

```
  pep.Nome_PEP AS [Nome_PEP], \
  pep.CPF_normalizado AS [CPF_PEP], \
  pep.Descrição_Função AS [Funcao_PEP], \
  pep.Data_Inicio_Exercicio_normalizado AS [Data_Inicio_PEP], \
  pep.Data_Fim_Exercicio_normalizado AS [Data_Fim_PEP], \
  pep.Data_Fim_Carência_normalizado AS [Data_Carencia_PEP], \
  pep.Municipio_normalizado AS [Municipio_PEP], \
  pep.uf_orgao AS [UF_PEP] \
FROM despesas_consolidado des \
JOIN empresas emp ON emp.cnpj = des.nr_identificador_despesa \
JOIN socios soc ON soc.cnpj = emp.cnpj \
JOIN peps pep ON pep.CPF_normalizado = soc.cnpj_cpf_socio AND pep.Nome_PEP =␣
 ↪soc.nome_socio'
```

[47]:
```
empresas_peps = pd.read_sql(sql, engine_banco_saida, index_col=None)
```

[48]:
```
empresas_peps.sample(5)
```

[48]:
```
   Nome_Municipio_Ficticio CNPJ_Empresa_Beneficiaria  \
28                    SITA           49524688000199
47                BUSSAMRA           59442647000146
24                   HANDA           07815964000138
64                MILLNITZ           12480500000115
9                COSLOVSKY           55815300000213

   Razao_Social_Empresa_Beneficiaria  Valor_Total        CNPJ_RFB  \
28                     IBAI VESTUARIO    339078.90  49524688000199
47            LOUISE ADMINISTRATIVOS    178798.02  59442647000146
24                 AMINE LIMPEZA EPP    425778.13  07815964000138
64                     VICENTE MODAS    131687.01  12480500000115
9                 AMINE IMOBILIARIOS    747635.06  55815300000213

         Razao_Social_RFB Situacao_Cadastral_RFB  \
28         IBAI VESTUARIO                 ATIVA
47  LOUISE ADMINISTRATIVOS                 ATIVA
24       AMINE LIMPEZA EPP                 ATIVA
64           VICENTE MODAS               BAIXADA
9       AMINE IMOBILIARIOS                 ATIVA

    Data_Situacao_Cadastral_RFB Codigo_Natureza_Juridica_RFB  \
28                     20200101                         2038
47                     20200101                         3999
24                     20200101                         2305
64                     20200101                         2305
9                      20200101                         3999

    Data_Inicio_Atividade_RFB  … CPF_Socio_RFB Data_Entrada_Socio_RFB  \
```

```
28                   20201019  …   ***460278**              20200101
47                   19891126  …   ***853118**              20200101
24                   20200127  …   ***396958**              20200101
64                   20140218  …   ***178358**              20200101
9                    19870728  …   ***890658**              20200101

                                          Nome_PEP      CPF_PEP Funcao_PEP  \
28                          SAVIOLO LUYTEN SMERIERI  ***460278**   PREFEITO
47  BENJAMIM HOSCHITAKE OBERLEITENER DE MOLIMAROLI  ***853118**   PREFEITO
24                             FABIO MUSSY DE BOYDE  ***396958**   VEREADOR
64                               JOAO YPEI DE KAARA  ***178358**   PREFEITO
9                              AMARILDO SABATE KAILER  ***890658**   PREFEITO

    Data_Inicio_PEP Data_Fim_PEP Data_Carencia_PEP Municipio_PEP UF_PEP
28       2017-01-01   2020-12-31        2025-12-31          SITA     SP
47       2017-01-01   2020-12-31        2025-12-31      NIRAZAWA     SP
24       2017-01-01   2020-12-31        2025-12-31       VIJARVA     SP
64       2017-01-01   2020-12-31        2025-12-31        GAZETA     SP
9        2017-01-01   2020-12-31        2025-12-31         SOLIZ     SP

[5 rows x 24 columns]
```

3.3.1 Salvar dados

[49]:
```
arquivo_saida = 'empresas_peps.csv'
filepath = os.path.join(diretorio_saida_dados, arquivo_saida)
empresas_peps.to_csv(filepath, index=False)
```

3.4 Consultar Empresas Relacionadas com Pessoas Politicamente Expostas que Receberam Recursos dos Municípios que Possuem Mandatos

[50]:
```
empresas_peps_mesmo_municipio = empresas_peps[empresas_peps['Municipio_PEP'] ==␣
↪empresas_peps['Nome_Municipio_Ficticio']]
```

[51]:
```
empresas_peps_mesmo_municipio.shape
```

[51]:
```
(11, 24)
```

[52]:
```
empresas_peps_mesmo_municipio.sample(5)
```

[52]:
```
   Nome_Municipio_Ficticio CNPJ_Empresa_Beneficiaria  \
15                   KNOLL           18941225000172
69                   ASSUB           49524688000199
52                 ROZARIO           08262075000137
41                   BREIA           10240793000137
54                  SACCOL           06273922000124
```

```
   Razao_Social_Empresa_Beneficiaria  Valor_Total        CNPJ_RFB  \
15         CSENGE CONFECCOES EIRELLI    555209.93  18941225000172
69                   IBAI VESTUARIO    113162.42  49524688000199
52           MARIUS CONTABIL EIRELLI    135193.38  08262075000137
41         JOAO LUCAS ELETRONICOS SA    225281.82  10240793000137
54            MOMOKA ARTISTICAS LTDA    141497.58  06273922000124

            Razao_Social_RFB Situacao_Cadastral_RFB  \
15  CSENGE CONFECCOES EIRELLI                 ATIVA
69             IBAI VESTUARIO                 ATIVA
52    MARIUS CONTABIL EIRELLI               BAIXADA
41  JOAO LUCAS ELETRONICOS SA                 ATIVA
54     MOMOKA ARTISTICAS LTDA                 ATIVA

    Data_Situacao_Cadastral_RFB Codigo_Natureza_Juridica_RFB  \
15                     20200101                         2232
69                     20200101                         2038
52                     20200101                         3999
41                     20200101                         3999
54                     20200101                         3999

    Data_Inicio_Atividade_RFB  … CPF_Socio_RFB Data_Entrada_Socio_RFB  \
15                   20120324  …   ***969658**               20200101
69                   20201019  …   ***271878**               20200101
52                   20030308  …   ***341758**               20200101
41                   20130111  …   ***502138**               20200101
54                   20000214  …   ***923478**               20200101

                                Nome_PEP      CPF_PEP Funcao_PEP  \
15                    JUNOR RUITA CHIMANGO  ***969658**   VEREADOR
69              JAIME BONAVOGLIA DA TEVEIRA  ***271878**   PREFEITO
52                 GOSSON LEGNANNE GONDOREK  ***341758**   PREFEITO
41  CAUME UNAIDE ABASILIA PHREDERICO ZIELAK  ***502138**   PREFEITO
54            GEOVANISA TERSINHA BERTASSONI  ***923478**   PREFEITO

    Data_Inicio_PEP Data_Fim_PEP Data_Carencia_PEP Municipio_PEP UF_PEP
15       2017-01-01   2020-12-31        2025-12-31         KNOLL     SP
69       2017-01-01   2020-12-31        2025-12-31          ASSUB     SP
52       2017-01-01   2020-12-31        2025-12-31       ROZARIO     SP
41       2017-01-01   2020-12-31        2025-12-31          BREIA     SP
54       2017-01-01   2020-12-31        2025-12-31        SACCOL     SP

[5 rows x 24 columns]
```

3.4.1 Salvar dados

[53]:
```
arquivo_saida = 'empresas_peps_mesmo_municipio.csv'
filepath = os.path.join(diretorio_saida_dados, arquivo_saida)
empresas_peps_mesmo_municipio.to_csv(filepath, index=False)
```

4 Visualização

4.1 Mapa de Localização de Empresas relacionadas à PEPs

[54]:
```
arquivo_municipios = 'Municipios_SP_paridade.csv'
filepath_arquivo_municipios = os.path.join(diretorio_dados, arquivo_municipios)
```

[55]:
```
municipios = pd.read_csv(filepath_arquivo_municipios, sep='|')
```

[56]:
```
empresas_peps_coord = pd.merge(empresas_peps, municipios, how="inner",␣
↪left_on='Nome_Municipio_Ficticio', right_on='Municipio_ficticio')
```

[57]:
```
empresas_peps_coord.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 73 entries, 0 to 72
Data columns (total 32 columns):
 #   Column                              Non-Null Count  Dtype
---  ------                              --------------  -----
 0   Nome_Municipio_Ficticio             73 non-null     object
 1   CNPJ_Empresa_Beneficiaria           73 non-null     object
 2   Razao_Social_Empresa_Beneficiaria   73 non-null     object
 3   Valor_Total                         73 non-null     float64
 4   CNPJ_RFB                            73 non-null     object
 5   Razao_Social_RFB                    73 non-null     object
 6   Situacao_Cadastral_RFB              73 non-null     object
 7   Data_Situacao_Cadastral_RFB         73 non-null     int64
 8   Codigo_Natureza_Juridica_RFB        73 non-null     object
 9   Data_Inicio_Atividade_RFB           73 non-null     int64
 10  CNAE_Fiscal_RFB                     73 non-null     object
 11  Municipio_RFB                       73 non-null     object
 12  UF_RFB                              73 non-null     object
 13  Nome_Socio_RFB                      73 non-null     object
 14  CPF_Socio_RFB                       73 non-null     object
 15  Data_Entrada_Socio_RFB              73 non-null     int64
 16  Nome_PEP                            73 non-null     object
 17  CPF_PEP                             73 non-null     object
 18  Funcao_PEP                          73 non-null     object
 19  Data_Inicio_PEP                     73 non-null     object
 20  Data_Fim_PEP                        73 non-null     object
 21  Data_Carencia_PEP                   73 non-null     object
```

```
 22  Municipio_PEP                      73 non-null     object
 23  UF_PEP                             73 non-null     object
 24  ID                                 73 non-null     int64
 25  IBGE_7                             73 non-null     int64
 26  IBGE_6                             73 non-null     int64
 27  Municipio_real                     73 non-null     object
 28  UF                                 73 non-null     object
 29  Latitude                           73 non-null     float64
 30  Longitude                          73 non-null     float64
 31  Municipio_ficticio                 73 non-null     object
dtypes: float64(3), int64(6), object(23)
memory usage: 18.8+ KB
```

[58]:
```
empresas_peps_coord.sample(5)
```

[58]:

	Nome_Municipio_Ficticio	CNPJ_Empresa_Beneficiaria	Razao_Social_Empresa_Beneficiaria	Valor_Total	CNPJ_RFB	Razao_Social_RFB	Situacao_Cadastral_RFB	Data_Situacao_Cadastral_RFB	Codigo_Natureza_Juridica_RFB	Data_Inicio_Atividade_RFB	…	Municipio_PEP	UF_PEP	ID	IBGE_7	IBGE_6
48	NIELAND	06273922000124	MOMOKA ARTISTICAS LTDA	195474.65	06273922000124	MOMOKA ARTISTICAS LTDA	ATIVA	20200101	3999	20000214	…	SACCOL	SP	426	3537800	353780
47	DALO	10240793000137	JOAO LUCAS ELETRONICOS SA	221294.85	10240793000137	JOAO LUCAS ELETRONICOS SA	ATIVA	20200101	3999	20130111	…	BREIA	SP	182	3515806	351580
13	CAVICHIOLI	55815300000475	AMINE IMOBILIARIOS	139074.12	55815300000475	AMINE IMOBILIARIOS	ATIVA	20200101	3999	20111019	…	SOLIZ	SP	132	3511607	351160
58	CLARETO	10240793000137	JOAO LUCAS ELETRONICOS SA	135392.02	10240793000137	JOAO LUCAS ELETRONICOS SA	ATIVA	20200101	3999							
71	ASSUB	49524688000199	IBAI VESTUARIO	113162.42	49524688000199	IBAI VESTUARIO	ATIVA	20200101	2038							

```
58                  20130111  …          BREIA     SP  160  3514403  351440
71                  20201019  …           SITA     SP   36  3503158  350315

    Municipio_real  UF Latitude Longitude Municipio_ficticio
48         PIEDADE  SP  -23.712   -47.428            NIELAND
47      FLORA RICA  SP  -21.676   -51.384               DALO
13   CESARIO LANGE  SP  -23.227   -47.953         CAVICHIOLI
58         DRACENA  SP  -21.483   -51.533            CLARETO
71          ARAPEI  SP  -22.674   -44.448              ASSUB

[5 rows x 32 columns]
```

[59]:
```
mapa_plot = folium.Map(location=[empresas_peps_coord.Latitude.mean(),␣
↪empresas_peps_coord.Longitude.mean()], zoom_start=7, control_scale=True)
for index, location_info in empresas_peps_coord.iterrows():
    description = "A empresa " +␣
↪location_info["Razao_Social_Empresa_Beneficiaria"] + " (CNPJ " +␣
↪location_info["CNPJ_Empresa_Beneficiaria"] + "), relacionada ao PEP " +␣
↪location_info["Nome_PEP"] + ", recebeu R$ " +␣
↪str(location_info["Valor_Total"])
    description.splitlines(True)
    folium.Marker(
        [location_info["Latitude"], location_info["Longitude"]],
        popup=description,
        tooltip=description,
        icon=folium.Icon(color="red", icon="info-sign")
    ).add_to(mapa_plot)
title_html = '''
             <h3 align="center" style="font-size:20px"><b>Mapa (fictício) de␣
↪empresas relacionadas com PEPs</b></h3>
             '''
mapa_plot.get_root().html.add_child(folium.Element(title_html))
mapa_plot
```

[59]:
```
<folium.folium.Map at 0x7f7ea2770250>
```

[ ]:
```

```